独立镜头一：零选择、统计决策与可辨识性

日期：2026-10-25。范围：任务定义、决策理论、可学习性与科学方向，不是工程审查、结果认证或实验启动方案。

用户指定研究角色为 gpt-6-astra/max；当前会话不能独立验证或切换服务端型号，故此名称仅记录请求，不冒称已认证该型号。本文实读两次旧调研、相关完成报告及有限的模型/目标函数片段以理解机制；没有读取预测数组重算指标、运行模型、检查或干预进程。仅创建本文与 01_sources.csv。native goal 保持 paused。

结论先行

1. 证伪**“当前零选择合理”**比证明**“Bayes 永不选择”**容易得多。 一个由允许输入识别、事先固定的区域若具有正的总体改选收益，就反驳当前策略在该区域的最优性；留出实例上的稳定净收益是其证据，仍受抽样及研发适应影响。不必先恢复真实后验，也不必证明该方法是全空间 Bayes 冠军。反过来，没有找到这样的区域，只能约束已经考察的策略类。 2. 缺的不是一个泛称的**“信号”**，而是特定决策所需的信号。 winner 支持、类内 AUC、可靠概率、跨候选可比性、输入条件充分性和净选择收益是不同证据。两两成本胜率即使完全正确，通常也不能识别全池冠军；可靠概率即使完全成立，也可以没有利用全部允许输入。 3. 新完成的 **R110** 收紧的是一个具体充分性假说，不是全部私有化或 **Bayes** 上限。 方法私有后段图计算加纯 CE 没有突破平台。下一步应围绕可检验的决策残差，而不是继续把更换 proper loss、增加候选分支或减少零组数当作信息增加。R109/R111 尚在进行，不给结论。

其中，正频率不强迫非零 argmax、Top1 与 regret 不等价、条件先验很强、共同错很多、TEST 已参与研发，都已在旧报告出现。本次增量是把这些边界变成可操作的否证对象，区分**“相对当前策略的改进见证”**与**“真实 Bayes 支持集”**，并明确哪些概率对象不能互相替代。

1. 事实前提与历史去重

当前讨论以 NEW90k 冻结版本为主：每题 TRAIN/VAL/TEST 为 81,000/4,500/4,500，18 题、seed2、逻辑 batch1024；候选删除及单一 reld_mt 不变。精确 Top1 对照保存的 native/FP64 ind，不重算 FP32 argmin。LEGACY18、NEW70114 与 NEW90k 的成绩不构成同一条因果学习曲线。

新增机械索引只用于定位材料；96 个目录、78 个编号包含 archive、恢复交付和复用控制，不能当成独立研究试验数。索引。下表是与本镜头直接相关的机制，不是逐版结果审计。

历史	实际读到的机制与证据	对本次推理的约束
R35–R40	两次旧调研记录单任务续训、小样本记忆、几何残差及拟合/泛化分离；另实读 R39：独立性能头、centered-cost MSE、性能 argmin，VAL 未胜分类控制。历史、R39	小样本可记忆不是全 81k 可学习证明；成本回归直接决定动作也不是未试方向。
R47、R69	R47 README 是 full18 TRAIN 行为记忆，键映射可训练，历史 gap/winner 进入上下文；R69 的完整 task-private bank 已见两次历史专题。R47	不把 R47 错写成局部 ReLD 二选一，也不再建议“第一次加记忆/任务私有网络”。
R71	实读 README、RESULTS 与 nll/winner_probabilities：八个全协方差高斯混合拟合联合成本差，Sobol 积分全池冠军概率。LEGACY18 B 的 TEST 45.1056%，复用控制 A 为 46.7167%。R71、实现	已有联合分布，不是独立成本回归；失败约束该密度、表示和继承训练组合，不能否定所有联合信息。

历史	实际读到的机制与证据	对本次推理的约束
R81、R82	R81 排序同方法跨实例的 competitive score；R82 在 TRAIN 条件组内排序连续相对 regret。原机制 PDF 的 TEST 平均适用 AUC 为 0.7888；R82 条件 AUC 为 0.6968、regret concordance 为 0.6471。R81、R82	两者均属 NEW70114，均无新训 matched A。AUC/一致性不等于跨方法冠军判别，也不能与当前固定36组直接合并。
R85	OVR、EQL 式平衡、非 winner 成本 profile、随机候选子池；报告中 TEST Top1 分别为 71.2321/71.2111/71.3111/71.4370%。R85	自然 BCE、候选子集及密集成本信息均非空白；保留的复合目标也限制单项归因。
R103	实读原报告：R94B 在同题同精确 N 保频次置换后，VAL Top1 71.4284%→67.7134%。R103	反对“仅靠题型/规模”；未控制其它生成条件，不证明每个漏选方法已有足够信息。
R98、R100	实读报告：前者估计每方法期望相对 gap；后者用所有 TRAIN 严格成本对训练二分类，包括第三方法是冠军的行，最终固定 Borda。R98、R100	期望风险、两两胜率、冠军后验已被不同机制分别触及，但不能将其统计对象互换。
R108	实读 MODEL_PREP、恢复完成报告和目标函数：两臂均用 s=log(pi)+t；A 用 CE，B 用联合对 product-noise 的密度比目标。TEST Top1 71.3383/71.2173%，regret 0.400252/0.399144%。R108、目标	没有实例净收益突破，亦不是完全无成本取舍；不能继续把“先验加剩余信号”当未试机制。
R110	实读完成 RESULTS：tied/private 的 TEST Top1 为 71.3074/71.2333%，actual regret 为 0.406464/0.399449%；固定36组命中为70/44。R110	私有化降低了该比较的 TEST regret，却未改善 Top1 或漏选恢复；两臂非等参数/FLOP，不支持唯一因果结论。
R109、R111	按本轮用户状态保持“进行中”。R111 仅读计划与概率路径：家族概率乘族内条件概率，全部合法叶子共同竞争。R111机制、实现	计划中的“未启动”和旧方向文中的 R110 running 都已过时；不读取中间成绩推测成败。

第二轮的 定量证据专题 已说明：R94B 的固定36组占错误约19.46%，完美且无害修复后的诊断 Top1 是 77.1099%；三模型共同错误、完整条件先验及近并列分解均已有记录。本文直接采用其报告口径，不重复计算，也不把这些数字称为本次发现。

2. 一个任务，至少三个决策对象

固定问题 $T=t$、合法池 L_t、求解器部署与 tie 规则。令 X 为允许的查询输入，Z 为实际用于决策的信息，C_k 为记录成本，$C_*=\min_{j\in L_t} C_j>0$，$Y$ 为 native winner。以下条件分布均隐含任务及合法池。

$$\eta_k(z)=P(Y=k\mid Z=z),\qquad \mu_k(z)=E[C_k/C_*\mid Z=z].$$

目标	理想条件动作	不需要、也不能由它替代的量
精确 Top1	$d_{01}^*=\arg\max_k \eta_k$	不要求胜出时成本优势很大。
题内 mean_cost、固定分母的 vs_SBS/均值比 vs_Oracle	$d_C^*=\arg\min_k E[C_k\mid Z]$	不等于平均相对成本；须注明 SBS 的拟合划分，事后最优只能明确标为参照。

目标	理想条件动作	不需要、也不能由它替代的量
actual regret	$d_r^* = \arg\min_k \mu_k$	$E[C_k/C_* \mid Z]$ 一般不等于 $E[C_k \mid Z]/E[C_* \mid Z]$。

随机的 Oracle 分母会改变实例权重。即使原始期望成本更低，也未必使平均相对 regret 更低。完整联合成本分布足以推出这些量，但最小化期望原始成本只需各成本条件均值；最小化相对 regret 只需各归一化成本条件均值；冠军概率则是联合分布中各“最小值区域”的质量。需要联合事件，不等于必须拟合整个连续密度。
R71 的 NLL 可以改善与这些区域边界无关的密度细节，R39 的全向量 MSE 可以改善不影响最终动作的方向。这是统计目标区别，不是已查实的项目根因。

SPO 明确区分预测误差与决策损失；但其 v5 §4 的一致性定理需要中心对称、连续条件成本分布、均值处唯一最优等条件。有限候选问题可借鉴决策损失，不能直接继承一个任意 neural selector 的保证。P8 本次不建议替换现有目标，更不重新依据 TEST 选 checkpoint。
ALL 的定义是 $18^{-1}\sum_t E[\ell \mid T=t]$。每题等样本数使当前 TEST 的实例计数恰好对应等题权重；它不是按候选平均召回，也不是部署中未知题型频率的平均。多个相似约束题可以共享困难机制，18 题不是18次独立证明。将 raw cost 跨题混合，更不能作为此风险的替身。

3. 零选择原因链：四个不能跳过的层次

这是一条待检验的解释链，不是已证实的单一因果链：

有 native winner 支持 -> 允许输入中有可利用的优势区域 -> 当前模型已形成可部署区分 -> 自然分布净收益

层次	真正要问什么	现有证据到哪里
有 winner 支持	$P(Y=k)>0$，且训练样本里有足够记录吗？	LEHD/DIFUSCO 有大量 TRAIN winner；但总量不等于每个条件区域支持。
有可辨识区域	是否存在仅由允许输入确定的规则，使选择 k 对相应风险更好？	粗条件众数不选它，不证明细粒度区域不存在；R103 整体关联也不保证特定方法存在这种区域。
模型已学会	模型是否把正确实例排到可跨候选比较的决策位置？	AUC、预测 rank 与 margin 提供不同局部信息；TRAIN 漏选说明失败不只发生在未见实例上。
自然分布有净收益	真救回、原正确被伤害、双方皆错的成本变化，合并后怎样？	选择次数变多不够；R110 private 的 Top1 与 regret 变化方向不同，已有直接提醒。

3.1 哪些零选择在理论上可以合理

旧决策专题已给出：即使 $P(Y=k)>0$，只要 $\eta_k(z) < \max_{j\neq k}\eta_j(z)$ 几乎处处成立，精确后验的 Top1 Bayes 规则也不会选 k。并列时是否选它还依赖 tie 规则。对相对成本风险，类似条件是 $\mu_k(z) > \min_{j\neq k}\mu_j(z)$ 几乎处处成立；若仅为大于等于，可能存在不选它的最优规则，也可能由并列规则选它。这两个条件不同，不能用一个低 regret 总数证明它们。

“当前表示下合理”不等于“完整输入下不可学”。 如果完整输入、执行状态和 tie 规则使记录输出确定，标签可以是确定函数；模型的压缩、函数类、有限样本与学习过程仍可能限制它。低维表示不自动意味着丢失信息，一个训练集上的唯一编码仍可供无限制查表；实际困难也可能是解码复杂性而非严格的信息丢失。没有重复执行证据，更不能把条件不确定性命名为 solver 随机噪声。

“置信度不够所以保守不选”也要拆开。普通 argmax 没有主动计算一个保守决策置信区间；有限样本的收缩或偏置可能压低少数方法，只是机制假说。若真实后验优势为

$$\delta_k(z) = \eta_k(z) - \max_{j \neq k} \eta_j(z) > 0,$$

且所有后验估计误差都小于 $\delta_k/2$，它必须被选中。当前缺的正是对真实优势和估计误差的独立约束，而不是再画一次当前模型的低概率。Audibert–Tsybakov 的 margin 条件讨论后验靠近分类边界的质量，不是 solver 的成本间隔；其速率还依赖平滑性和密度条件。P4，§1 MA、§3 Theorem 3.3、§5 Lemma 5.1

3.2 哪些零选择可以被现有信息否证

固定一个已锁定完整策略 $d_0(X)$，以及一个只用允许输入、在评价标签之前确定的区域 A。设新规则只在 A 改选合法方法 k。定义逐实例比较量

$$W_k = \mathbf{1}\{Y = k\} - \mathbf{1}\{Y = d_0(X)\}, \qquad G_k = \frac{C_{d_0(X)} - C_k}{C_*}.$$

那么它相对旧策略的 Top1 增量和 actual-regret 减少量恰好是

$$\Delta_{01}(A, k) = E[\mathbf{1}_A W_k], \qquad \Delta_r(A, k) = E[\mathbf{1}_A G_k].$$

这是本文用于项目问题的直接恒等式，不是任何论文已证明本数据具有正收益。公式中的准确率、regret 和增量以比例计；报告百分数需乘100，Top1 增量对应百分点。它带来三个重要区别。

第一，不必要求改选方法 **precision 超过50%**。 多分类中旧策略在该区域可能只有20%正确，新方法30%正确，虽大多数改选仍非 native winner，Top1 却净增。反之，较高 recall 若伴随更多原正确被破坏，仍可能净负。对成本还必须保留“双方都错”的节省，不能只统计救回与误选标签数。

第二，总体正收益见证只否证当前策略，不自动证明 k 有 **Bayes** 最优区域。 它可能优于 d_0，但存在第三方法更好。旧报告提醒“粗组内频率最高不等于细信息下处处第一”；本次补上实践上更弱、却足够有用的判据：先寻找相对当前策略的可泛化增益证据，无需先解决全部 Bayes 识别问题。

第三，没有找到正收益，可能是区域类太弱、样本不够或估计不准，不等于不存在区域。真正可以称“在本轮限制下没有必要强行选”的，是对明确规则集合与风险容忍量得到有用上界，而不是对所有图函数作无证据的全称判断。

3.3 校准通过也可能没有学会

概率可靠性 $P(Y = k \mid q(X)) = q_k(X)$ 比“全体平均概率正确”强，却仍弱于 $q_k(X) = P(Y = k \mid X)$。Vaicenavicius 等 §2 式(1)–(3)区分全向量、最高置信度及逐类校准；§3 Proposition 1
表明任何粗化信息的真实条件概率都可可靠，常数先验也是例子。P1

因此，一个完全可靠、但在某方法上从不 argmax 的模型，仍可能遗漏允许输入里的决策线索。反过来，只见校准误差也不能断言重新校准会救回它：误差可能改变概率数值却不改变动作。需要分别问：在相同预测状态下，额外输入是否解释 W_k, G_k；或仅靠已有预测状态是否已经存在系统性净收益？
前者指向遗漏的输入利用，后者更接近读出/跨候选可比性。

校准分析还必须使用与训练及推理对应的分数：R81 的 competitive score、R85 的 Bernoulli sigmoid、原 maximin 的 softmax、R108 的 log(pi)+t、R71 的积分概率不能混叫同一种后验。argmax 相同不等于概率含义相同；标量正温度又不会改变 argmax。这里是机制理解，不是要求改动任何实现。

4. AUC、候选关联和家族概率的三处陷阱

4.1 AUC 好，缺的仍可能是跨方法决策

同一方法的 AUC 比较的是不同实例上的分数顺序；最终 argmax 比较同一实例的不同候选。对某列分数作严格递增变换不改变它的 AUC，却一般改变跨列竞争。Agarwal 的 Theorem 13 是“强 proper 代理风险小可推出二分类排序 regret 小”的单向界，不是“AUC 高可推出多类 argmax 好”的逆命题。P2，§§2–3、§5.1

原 v2 已有鲜明实证：R94B 的 CVRP/RouteFinder margin AUC 为0.8714，仍无命中；LEHD 和 DIFUSCO 的名次分布也不同。这些不作为新发现。新增解释是：即便固定某阈值，精确率还取决于自然 prevalence π、TPR t、FPR f：

$$\text{precision} = \frac{\pi t}{\pi t + (1-\pi) f}.$$

AUC 是整条曲线的排序摘要，不告诉我们当前竞争者对应的动作区域里 W_k 的条件均值是否为正。R81 已直接训练跨实例 AUC，R82 又控制部分 context；其有限结果削弱“改好这一列排序就足够”的猜想，但未排除更强实例特征。不能因此再推荐一个换名的 AUC 或条件排序目标。

4.2 两种 pairwise probability 不能套同一个 coupling

Wu–Lin–Weng 的多分类概率耦合输入是

$$r_{ij}(x) = P(Y = i \mid Y \in \{i, j\}, x) = \frac{\eta_i(x)}{\eta_i(x) + \eta_j(x)},$$

而 R100 的对象是 $P(C_i < C_j \mid x,\ C_i \neq C_j)$，训练中保留了第三方法为全池 winner 的样本。前者条件在互斥冠军标签集合上，后者问两个成本谁低；两者通常不同。论文 §1–2 明确了式(3)对象，§3–4 的耦合不能直接把后者变成冠军概率。P3

为明确“关联缺失”究竟指什么，下面给出本次用于说明的三方法构造。每个排序内成本依次为1、2、3，无数值并列；两行都是合法分布。

成本从低到高的顺序	ABC	ACB	BAC	BCA	CAB	CBA
分布 U 的概率分子，分母12	3	2	1	2	1	3
分布 V 的概率分子，分母12	1	2	3	2	3	1

两行任意两方法的胜率都是1/2；U 的冠军概率为 $(5, 3, 4)/12$，V 为 $(3, 5, 4)/12$，唯一最优冠军动作却从 A 变成 B。故连精确 pairwise 成本胜率都不足以识别冠军，问题并非必然来自预测器不准。v2 已有“pair 边际不足”的结论；本次补充的是它与经典概率耦合的适用对象区别，不能把旧结论重新包装为全新理论。

R71 已经绕过这种 pair 边际缺失，拟合全成本差联合分布，仍未成功。这阻止把“补关联”直接提升为下一万能方案。候选来源接近、checkpoint 相关也不自动意味着条件成本相关的具体形式已知。家族身份可以是有效结构假说，却不是独立算法数、独立信息量或可识别优势的证明。

4.3 R111 应考察软乘积，而不是只看根准确率

R111 使用 $p_m = \pi_{f(m)} q_{m \mid f(m)}$，且全池比较，不是先选最大家族再在族内选方法。家族总质量最大，不意味着其中任何成员概率最大；族内质量分散时，第二大家族的集中成员可能赢。因此，根 family Top1 和“在真实家族里”的 conditional accuracy 都不能单独充当最终 Top1。

一个将来可直接从锁定输出检查的限制是：固定根及其它家族输出时，若真实方法所在族满足

$$\pi_{f(Y)} < \max_{j \notin f(Y)} p_j ,$$

则把该族内真实方法条件概率理想化为1，仍救不回该例；单独修复该族内分支无效，还需改变根概率或族外竞争者概率。反过来，不满足式(4)也不意味着族内可被实际学会。这个“理想族内修复”只分解已有错误，不能作为部署策略；精确等号保留原 tie 规则。本次没有读取或计算 **R111** 的这些量，也不提前宣称哪一路是瓶颈。 它是从当前机制导出的可否证解释，而非重推一个分层方案。

5. ALL 平台原因链：不是把零选择链扩大18倍

第二条解释链是：

数据/合法池/任务权重固定 -> 各题先验与剩余竞争难度不同 -> 学习器共享或不同的误差 -> 改选的纠正与伤害抵消 -> 约71%的宏平均

这里每个箭头都是待分辨的贡献，不是认定某一项已充分解释平台。

链条位置	采用旧证据或新完成事实	能说 / 不能说
任务定义	LEGACY18 到 NEW70114 同时变数据和候选；NEW90k 又冻结新成员。	可比较同版本结果；不能把旧47%到新71%视为架构突破。
任务混合	v2：五个低准确率题承担55.63%错误、39.82% regret；不少高准确率题只略超条件先验。	ALL 相同可由不同误差结构形成；“每题都达到71%上限”不成立。
局部零选择	v2：固定36组约占五分之一错误。	这是有价值的子问题，不是整个平台的充分解释。
决策取舍	v2 的纠正/伤害抵消；新 R110 private 又出现 Top1 更低而 TEST regret 更低。	同一总分可掩盖换错样本与风险取舍；不等于任何取舍都是最优。
学习限制	多模型共同错、TRAIN 也漏；R110 的私有化+纯 CE 未突破。	削弱简单修补的充分性；不能把共同错当不可约错误。
研发证据	同数据、同 seed、复用输入/控制及自适应研究历史。	一系列负结果并非一系列独立统计反证；也不能以“不是独立”抹掉每项具体反证。

大成本差只说明错选代价大，不保证在允许信息下后验 margin 大。反过来，精确 winner 边界附近可能确实难学，但 v2 的“零损失错例仅116/23,022，所选超额>1%的错例贡献约81.58% regret”已经反对“平台主要无害近并列”。保存的 native 精确标签不应被近优集合替换；近并列只作为解释维度，不能改变成功指标。

小 TRAIN–VAL 差兼容共同欠拟合、有限函数类限制、收缩估计和接近某种条件最优；不能单凭它给出 Bayes 上限。小样本记忆只提供存在性见证，非样本复杂度或经济可学习性证明。R110 又把参数从约230万增至约1022万而未得到联合改善，这反对该具体私有化足够，但既不证明所有容量无效，也不证明过拟合是唯一原因。

多轮 TEST 反馈形成的研发适应，与单次训练对 TRAIN 过拟合是两件事。Dwork 等的 reusable-holdout 结果依赖受控反馈机制，不能事后把普通反复看 TEST 变成该定理保护下的评估。P7，§4.1、Figure 1、Theorem 25 本文只作探索性机制判断：不再用 TEST 挑当前模型或区域、不创建新划分；未来确认研究结论需另有未参与研发的证据。历史微小差值不获得自动显著性证书，负结果也不自动等于“已证无效”。

6. 只建议两项无训练分析，不在本轮执行

不再重做 v2 的全局先验、union、gap 桶或几十项数据审计。下面两项只需要已保存且身份明确的锁定输出、原有元数据和监督；若输出缺失，记录缺失，不补跑模型。它们的作用是决定下一科学问题，不是选择当前版本的新推理规则。

A. 一张相对当前策略的净收益图

对同一个完整锁定参考模型，以任务、候选及当前预测竞争者为轴，用已存候选 margin 的 TRAIN 固定分位区域作展示；区域不能根据 VAL/TEST 的真实 winner 搜索。每个区域只列覆盖数、式(1)的正/负/零计数、式(2)的 Top1 与 regret 净变化，同时列原正确被伤害及双方皆错的成本变化。固定36组可作预先声明的切片，但完整合法池与非目标实例不得消失。

它回答：现有分数是否已经能定位值得改选的区域？ 若正收益在预定区域稳定出现，便得到反对当前策略在该规则类内最优的证据，而非自动获得总体最优性检验的结论；若正例和旧正确实例始终混杂且没有正净收益，便削弱“只欠一个偏置/阈值”的说法。若 Top1 与 regret 的符号相反，首先承认目标取舍，不强行找联合成功措辞。

不能把图上的最好 VAL/TEST 区域临时拼成策略，也不能把每个候选都换成真 winner 来叫 rescue。精度低于50%不自动失败、AUC高不自动成功，判断只看相对旧动作的有符号增量。样本少的区域标为不确定；普通置信区间不覆盖研发自适应带来的全部不确定性。

B. 一张“概率错误还是遗漏输入”的交叉表

保持同一参考策略和同一分数语义，在预先固定的预测向量摘要内，分别比较预测的冠军概率差与观察到的 W_k，再看已有 input-only
条件字段能否解释剩余的有符号差异。必须减去各实例自身的预测概率差，仅观察粗分箱内 W_k 随输入变化，不足以区分遗漏输入与箱内预测差异。只采用少量有明确语义、预先固定的交叉，不进行以错误为目标的任意聚类。若已存的是非概率 decision score，先只报告条件经验胜率与 W_k，不把 softmax 值强称为真实后验。

预测状态内就有系统性差异，支持概率可比性或读出残差假说；预测状态近似可靠，但允许输入细分后仍有稳定差异，支持模型未利用那部分输入。两者都未见，不证明充分性，因为有限摘要和有限样本只检验了有限条件。

这不是 R103 的重新置换：R103 问现有分数与实例对应是否有用；本表问给定现有预测以后，是否还存在与可部署决策有关的遗漏条件。也不是 R108 的再训练：不改先验、不拟合密度比、不做阈值搜索。其限制与反例必须和正结果一起交付。

7. 两条有实质区别的研究方向

方向一：用可计算的决策残差见证引导学习

研究命题： 某些模型已经接近全局或粗条件概率平衡，却存在可由允许输入识别的局部区域，那里候选与当前竞争者的概率差被系统性估错，并对应正的决策增量。研究对象不再是“使少数类多被选”，而是找到这种可泛化的区域描述，并使模型学会描述所依赖的输入关系。

形式上，给定明确的 input-only 函数类 $\mathcal{H}$，考察

$$E[h(X)\{\mathbf{1}(Y=k)-\mathbf{1}(Y=d_0(X))-(q_k(X)-q_{d_0(X)}(X))\}],\quad h\in\mathcal{H}.$$

式(5)非零是相对预测的条件矩违背，不自动等于净收益；必须再通过式(2)连接实际决策。它可以指导“还需要学什么特征”，而不是把所有正例一律重加权。Hébert-Johnson 等的 multicalibration 将可计算子群上的校

准与弱 agnostic learning 联系起来；其有限样本保证要求足够大的子群及受控自适应查询，不能直接当成多类图选择器保证。P6，§§2–4、Algorithm 1、Theorems 1–3

最近历史及差别： R81/R82优化跨实例排序；R85A优化整列 OVR；R108通过固定 problem×N 先验重参数化后验；R92树模型直接拟合 winner/gap；R66/R78已有残差或分数修补。这里真正不同之处必须是可解释的输入区域发现、条件矩反证与决策增量相连接，让结构描述进入学习路径，而非又一个 residual head、全局 bias 或平衡权重。如果最后只学到 task/N 常数，方向就退回已有 R108 类机制，没有新意。

原信息限制下可以否证。 所有区域成员资格只读允许输入；query winner/cost
只用于监督，不能决定前向路由。既有 TRAIN 可提出描述，现有 VAL
可用于探索性反证，不更换划分；其发现仍需遵守 TEST 已暴露的结论边界。若区域只在 TRAIN
成立、条件细分后消失、只有 AUC 增长而预先指定目标的 Δ_{01} 或 Δ_r 没有改善，或规则依赖 query 求解结果，这条具体假说应停止。没有足够区域支持时，结论是当前见证不可识别，而非追加大规模标签生成。

优先级：条件保留。 先由第6节的两张小表判断是否有值得学习的见证；没有见证，就不凭论文名启动新的模型。即使有，也不承诺同时提升 Top1 和 regret，更不保证从新分区直接得到一个优于原完整池决策的部署器。

方向二：建立“相对明确策略类”的遗漏价值边界

研究命题： 对每个方法，不再问一个无法由有限记录无条件回答的“它有没有 Bayes 区域”，而是问：在某个透明、预先限定、部署可计算的规则类内，允许它参与切换最多能带来多少收益？这是可辨识性与统计决策理论方向，不是第二个待训练网络。

令 $\mathcal{D}_0$ 是预先指定的比较策略类，$\mathcal{D}_k$ 是在同一输入限制下额外允许相应 k-切换的类，且 $\mathcal{D}_0 \subseteq \mathcal{D}_k$。定义

$$V^{\ell}_{k,\mathcal{D}} = \inf_{d \in \mathcal{D}_0} R_\ell(d) - \inf_{d \in \mathcal{D}_k} R_\ell(d) \geq 0.$$

旧专题的 Bayes 遗漏价值对所有可测决策取最优；式(6)明确收缩到可检验的类。针对有限的、评价前固定的规则集，若各风险估计具有同时误差界 ε，两组最小风险之差的误差至多 2ε
。若是无限函数类，则必须给复杂度、平滑性或其它可验证假设，不能直接套有限集结论。Top1
损失有界；相对成本可能有长尾，没有有界性或矩条件时也不能照搬同一浓缩界。

最近历史及差别： R96 的模型 union 是知道答案后的逐实例选择，不是可部署规则类；v2 完美修复36组是机会预算，不是风险价值估计；R103 测已有分数依赖；R71估完整联合密度。此方向不再估整个密度，也不把 oracle union 当上限，而是为一个明确比较集合给出“有利、无足够收益证据、不可识别”三种结果。第4节的 pairwise 构造还提示：若约束只给成本对胜率，冠军价值区间可很宽；不能用更漂亮的 point estimate 隐藏未识别部分。

原信息限制下可以否证，但有边界。 一个合法规则若在有效的不确定性控制下具有正收益下界，即可反对“该类内无需选择”；若所有规则的收益上界都低于事先有科学意义的量，可支持暂缓该类切换。若区间很宽，或换一个同样合理的规则类就改变结论，停止全局“合理零选择”的说法，报告假设依赖。当前自适应使用过的 VAL/TEST 不自动满足上述同时误差界，此处是需要证明和验证的科学对象，不是本次已颁发的证书。

优先级：研究性保留，非立即性能干预。 它能把“学不到”缩成可被反例推翻的命题，并区分可利用性与剩余未知；不会增加原输入信息，也不保证提高准确率。若只能依赖未知 Bayes 后验、重新运行 solver 或大规模新标签才能界定，便不符合本项目当前边界，应否决该具体构造，不把任务转成数据审计工程。

哪些不建议继续包装为新方向

仅换 CE/OVR/密度比、把全部 pair 差 MSE 换个名字、重新宣布联合分布/记忆/私有化空白、按候选频率设置配额，均缺少本轮的新证据。R111 已在研究家族条件特征，不能重复启动另一套相同概念。候选来源信息、精确 ties 和语义问题可以影响解释，但不足以作为当前所有错误的通用原因；R58 继续 defer。本镜头不提供 GPU、预算、launcher 或模型晋升安排。

8. 八篇一手文献与适用边界

均于本轮通过浏览工具打开原论文正文，读取下列 method/theory 位置，不以摘要代替；完整可机读记录在 01_sources.csv。基础理论比凑近年架构更符合本镜头，P4/P8 属旧调研已有论文，本次仅重核及限界。

来源	本轮读到的位置	可用结论、假设与项目差异
P1. Vaicenavicius et al., 2019, Evaluating model calibration in classificatio n	§2式(1)–(3)；§3 Proposition 1；§4 Theorem 1	区分校准层次；分箱一致性有平滑/分区条件。可靠性不保证利用完整输入，ECE小不认证零选择合理。
P2. Agarwal, 2014, Surrogate Regret Bounds for Bipartite Ranking via Strongly Proper Losses	§§2–3；§5.1 Theorem 13；§5.2 logistic例子	二分类实例排序的一侧代理界；需要强proper损失，非多类argmax逆定理，非R81有限训练保证。
P3. Wu, Lin & Weng, 2004, Probability Estimates for Multi-class Classification by Pairwise Coupling	§1对象；§2式(2)；§3 Theorem 1；§4	耦合互斥类条件概率，正pair概率支撑其解性质；R100成本对胜率不是此输入。
P4. Audibert & Tsybakov, 2007, Fast Learning Rates for Plug-in Classifiers	§1 MA；§3 Theorem 3.3；§5 Lemma 5.1	后验margin和平滑/密度决定特定学习率；不是成本gap，也不提供本数据Bayes误差估计。
P5. Lipton, Wang & Smola, 2018, Detecting and Correcting for Label Shift with Black Box Predictors	§3 A.1–A.3；§4式(1)、Proposition 2	label shift要求 $P(X \mid Y)$ 不变、支持和可逆混淆矩阵。候选删除会改变Y，不能直接叫prior shift；零选择可能使硬混淆矩阵奇异。
P6. Hébert-Johnson et al., 2018, Multicalibratio n: Calibration for the (Computationally-Identifi able) Masses	§§2–4；Algorithm 1；Theorems 1–3	可计算子群与弱学习的桥梁；样本支持及自适应控制不可省。本文多类、有成本的见证只是研究延伸。
P7. Dwork et al., 2015, Generalization in Adaptive Data Analysis and Holdout Reuse	§1；§4.1；Figure 1；Theorem 25	受控holdout反馈可保障自适应分析；本项目历史未采用该机制，不能追认保护，也不能倒推出已有差值全是噪声。
P8. Elmachtoub & Grigas, Smart “Predict, then Optimize”, 作者v5, 2020	§3 Definition 3；§4 Assumption 1、Theorem 1；Appendix A Examples 3–5	决策损失与预测损失分开；连续、中心对称、唯一最优和内点前提未在项目成立。one-hot池涉及仿射降维，不能照搬保证。

P5 还约束一个易被忽略的说法：NEW90k 的合法先验是值得保留的输入统计，但“换池后约71%”不是只修正旧类比例的问题。删除竞争者会改变冠军事件，甚至改变 $P(X \mid Y)$。R108 已测试在当前池内的条件先验残差，不是旧/新池间 label-shift 校正；继续作先验文章必须说清改变的统计对象。P5

交给综合者的最终边界： 目前可以否定若干“单一修补足够”的简单叙事，可以提出原信息限制内的正收益见证；不能认证某漏选方法没有 Bayes 区域，也不能认证71%为学习上限。本轮不需要庞大数据审计才能取得进展，真正需要的是把可部署增益、概率可靠性和信息充分性的不同命题分开。