冻结完整选择器的条件集成：支持域、统计目标与三种科学表述

日期：2026-10-30。历史资料基准为2026-10-28；当前工程事实仅采用本轮Sol给定信息。

科学综合请求 gpt-6-astra/max；接口返回身份见 ROUTING.json，非独立后端认证。

本轮已读取指定的 HANDOFF.md 与 历史REPORT.md，并联网打开原论文核对引用；Astra依据这些历史全文、来源记录及原文摘录完成科学综合。未读取实验代码、结果或D1采集目录，未核验运行。新接口不是现有代码事实；旧快照仅作历史。下文的信息、支持域与风险关系均明确作为本文推导，不冒充文献或实验结论。

一、事实与问题定位

据给定记录，R123冻结完整R77B/R80A/R83，新建graph4layer128原图门，以三个独立二元正确性Brier目标训练；全对时目标均为1，全错时均为0。门不见专家输出，只执行选中的选择器并输出其全池排名。TRAIN来源记录未见交集每题10,886，属于条件队列，并非内容或同base新颖性认证。正式full18 TEST为Top1 71.30%、regret 0.39487%；冻结R77B约为71.26% / 0.39444%，变化可忽略。R124是独立full18 Top2专家，71.33%，纠正879、误伤823；R122硬成本 / 漏组惩罚更差。这些记录未经本轮导入复查，亦非匹配因果比较。

答案是有条件地可以：冻结意见可能把难计算预先完成，但不会凭空增加当前查询信息，也不保证元学习更容易。 R123的近零变化约束的是“原图→专家正确率→硬选择”，尚未直接回答“完整专家意见是否提供较易解码的条件偏好”。

二、信息与目标：不能把三个问题混成一个

令 X 包含任务及合法输入，Z 为冻结完整选择器的全池意见，H 为可选冻结表示。候选ID和有限合法mask必须对齐；这里的分数、概率及表示只是研究接口。仅有排名不足以定义软混合；下文的概率向量是规范化预测接口，不把现有分数自动视为校准概率。

给定固定专家权重 Θ，有：

$$I(Y; Z, H \mid X, \Theta) = 0.$$

因此，意见可能相对压缩原图门特征增加可用信号，或降低重新计算结构的样本 / 计算负担，却没有增加超出完整 X 的查询信息。若元模型仍须从高维表示重新发现全部优势规律，原来的困难就会回来。

所有表述的前向仅允许合法输入、冻结输出 / 表示，以及排除当前查询和同base拷贝的TRAIN上下文；不读取当前真winner、成本或求解结果。执行多个选择器是额外推理，不是执行多个solver，也不免费；元计算后仍只部署一个solver。

目标语义分别为：

$Y=$ native/FP64保存的ind，不以FP32 argmin替代，

$$r_a = (C_a - C_*)/C_*, \qquad \mathbb{E}_{18} = \frac{1}{18}\sum_{t=1}^{18}\mathbb{E}_t,$$

$$a_{\mathrm{acc}}(U) = \arg\max_a P(Y = a \mid U),$$

$$a_{\mathrm{reg}}(U) = \arg\min_a \mathbb{E}[r_a \mid U].$$

其中 $C_* = \min_{a \in \mathcal{A}_t} C_a > 0$ 是同一实例合法候选池的Oracle成本；U 只含允许的前向信息，C、Y 只作监督或历史TRAIN上下文。

自然winner准确率与距离regret一般不同，不能混合任务raw cost。正winner频率也不要求正最优动作频率：若给定合法信息的后验恒为 $(0.6, 0.3, 0.1)$ ，后两类可以永不成为最优Top1动作。这只是概念反例，不是本项目的Bayes上限或随机标签结论。

R123的独立Brier并非天然错误。对 $b_k = 1[a_k = Y]$，平方损失的条件最优预测正是 $P(b_k = 1 \mid U)$，用于硬专家选择完全自洽；它不是互斥类别分布，也不是软混合贡献概率。全错目标相同丢失了错法之间的排序和风险差别，但硬门本来也救不了全部专家Top1都错的查询。严格proper所保证的是其指定预测对象，不是任何经验评分改善都会改变动作。S07

三、支持域：软混合既比硬路由宽，也有精确边界

以下均为本文推导。固定查询，令 z_{ka} 为专家 k 对候选 a 的分数，$v_a = (z_{1a}, \ldots, z_{Ma})$ 。硬路由动作支持仅为各专家实际Top1的集合；随机抽专家也不会扩大它。共同凸池则为：

$$s_a = \alpha^\top v_a, \qquad \alpha \in \Delta_M.$$

构造例一：从未成为专家Top1的候选可以成为混合Top1。

	A	B	C
p_1	0.50	0.10	0.40
p_2	0.10	0.50	0.40
$(p_1 + p_2)/2$	0.30	0.30	0.40

两位专家都不选C，平均概率却选C；若真winner为C，软池能救回硬路由不可能救回的查询。

构造例二：没有单个对手统一支配，仍可能完全不可达。

$$p_1 = (0.30, 0.60, 0.10), \qquad p_2 = (0.30, 0.10, 0.60).$$

$$v_A = (0.30, 0.30), \quad \tfrac{1}{2} v_B + \tfrac{1}{2} v_C = (0.35, 0.35) > v_A.$$

B、C各自都没有在所有专家坐标上压过A，但它们的凸组合做到了。任何共同权重下，至少一个对手高于A；输入相关权重也绕不过这个逐查询限制。

令 $b \prec a$ 表示同分时b优先。实际输出a的精确可行判据是存在同一组权重满足：

$$\alpha \in \Delta_M, \qquad \alpha^\top (v_a - v_b) > 0, \quad b < a,$$
$$\forall b \neq a.$$
$$\alpha \in \Delta_M, \qquad \alpha^\top (v_a - v_b) \geq 0, \quad a < b,$$
$$\forall b \neq a.$$

只问能否进入argmax集合时全部用非严格不等式；要求唯一第一时全部严格。凸组合对手的完整障碍还可写成：

$$\gamma_a = \max_{\alpha \in \Delta_M} \min_{b \neq a} \alpha^\top (v_a - v_b)$$
$$= \min_{\beta \in \Delta_{A \setminus a}} \max_k \left(z_{ka} - \sum_{b \neq a} \beta_b z_{kb} \right).$$

这是有限线性极小极大关系：$\gamma_a \geq 0$ 当且仅当允许并列时可达；$\gamma_a > 0$ 当且仅当可唯一胜出；$\gamma_a < 0$ 当且仅当某个对手凸组合在每个专家坐标严格胜过a。仅弱支配时必须保留同分分析，不能一概删除候选。

这是闭单纯形的表达上限，受限权重模型可能更窄。利用 γ 选择可行权重的是不可部署oracle；凸包内存在，不等于可从合法意见学得。

四、三种实质不同的表述

1. 条件预测池：学习“何种意见形态下相信谁”

统计对象是条件预测分布。信息流为：

$$X \to \{E_k^{\text{frozen}}\} \to (t, Z) \to \alpha_\theta(t, Z) \to q \to \arg\max q.$$

TRAIN监督是native γ 上的类别CE或类别Brier，不是将专家正确率归一化。条件权重可以部分汇聚，表达稳定共享规律与局部偏好；相同专家意见使权重不可辨识，但预测分布仍可能有意义。层次stacking提供这种统计组织方式，不保证本项目收益。S05

概率池与logit池必须分开：

$$q_a^{\text{prob}} = \sum_k \alpha_k p_{ka},$$
$$q_a^{\text{logit}} = \text{softmax}_a \left(\sum_k \alpha_k \ell_{ka} \right)$$
$$= \frac{\prod_k p_{ka}^{\alpha_k}}{\sum_b \prod_k p_{kb}^{\alpha_k}},$$
$$p_k = \text{softmax}(\ell_k).$$

前者在概率凸包内，后者是归一化几何池，一般不在同一个概率凸包；上一节分别适用于各自的分数坐标。混合不自动保持校准，但固定正权分布池的过离散定理也不是所有动态多类门失败的定理。S06 总体、无约束预测空间中的严格proper一致性不能直接覆盖受限凸包和有限优化。S08

反证含义： 若关键winner几何上不可达，否定“共同凸池足够”；若可达却意见无法稳定对应所需权重，削弱“条件偏好容易学”的假设；只有log-score改善不支持Top1收益。S05的分离、已知区域及对数分数条件不能省略。

2. 广义stacking：重新判别候选，而非分配专家份额

计算类改为：

$$X \to (Z, H) \to F_\theta(t, Z, H) \to q,$$

$$s_a = \sum_k w_{ka} p_{ka}, \quad q = \mathrm{softmax}(s)$$

其中线性式只是类特定例子，通用 F 还可利用跨候选关系。w_{ka} 不再是所有候选共用的单纯形权重；分数本身也不自动是概率。原始stacking并未限制为共同凸池，Ting–Witten的多类回归同样使用类特定系数，因而这里不是全新广义技术。S01 S03

TRAIN目标是 $P(Y = a \mid t, Z, H)$。同样的意见可经更自由的映射走出原凸包，扩大的是函数类，不是输入信息。H 只有包含尚未编码进 Z 的相关信号时才可能有增量；即便 $I(Y; H \mid Z) > 0$ ，也不保证有益argmax发生变化，更不保证降低代价。

反证含义： 更自由的模型若只改善TRAIN或概率拟合，表示差异却不能稳定对应纠错，就不支持“预计算降低负担”。R105/109/110的门控及私有表示历史限制了“加表示必有效”的解释；这里的区别必须是完整历史决策意见的复用，而非又增加随机表示容量。

3. 意见条件的行动风险：直接学习每个动作的损失

统计对象改为逐动作条件均值，而非winner后验或联合成本密度。以意见profile连接合法TRAIN上下文：

$$U = (t, Z, c_{\mathrm{TRAIN}}(t, Z)), \qquad X \to Z \to U \to \hat{m}(U) \to \arg\min_a \hat{m}_a(U),$$

$$m_a(U) = \mathbb{E}\left[\frac{C_a - C_*}{C_*} \middle| U\right].$$

上下文绑定历史完整损失、winner与mask，排除当前 / 同base记录；当前查询仍没有成本观测。训练对象是完整损失向量的条件均值，也可等价写成相对合法基线 $b(U)$ 的差：

$$\Delta_a(U) = \mathbb{E}[r_a - r_{b(U)} \mid U], \qquad \arg\min_a \Delta_a = \arg\min_a m_a .$$

必须先逐实例归一化再取条件期望，不能换成均值比。固定类代价矩阵 $L(a, Y)$ 不包含实例成本幅度，无法替代完整TRAIN成本；成本矩阵校准与0–1校准本来也不同。S09

R47 / R97–100相关历史已包含强检索、上下文与成对比较，不能称首次上下文学习；META-DES也使用历史局部正确性和相似输出profile，但其相关元样本不是额外独立样本。S04 与R71的联合成本密度相比，此处只学习决策所需均值。SPO提供决策损失视角，其一致性条件不能直接移植。S10

反证含义： 相近意见若没有可迁移的风险结构，或均值拟合改善却没有改变错误argmin，机制便受削弱。regret下降而native Top1下降是目标取舍，不是共同突破，也不能靠选择频数配额消除。

五、如何解释历史，而不是重新命名历史

三种表述分别定位于凸包内条件权重、凸包外候选再判别、行动风险统计量，不是三个门网络变体，也不要求叠加。R124的纠正 / 误伤记录没有证明这些信息能提前区分两者；R122也不能被解释成所有成本风险目标均无效。

这不同于把R78式校准再做一遍：校准不能补回丢失的信息，评分进步也未必推动正确边界。R115的响应迁移失败仍是约束；历史已经指出，响应预测成功未必转为选择收益，seed受控的一次实现差不等于条件期望响应。本报告不把这些警告改写成新发现。

文献中的排除样本或交叉验证level-one构造，不能直接等同于当前来源记录未见交集，更不能推出同base独立性。S01 S02 历史选型 / 开发的TEST暴露，以及条件队列向自然18任务总体的迁移，仍限制泛化解释；这里将其作为假设边界，不安排审计或重训专家。

科学上最合适的判断不是“混合必胜”，而是：完整意见可能预计算可迁移的优势结构；几何可达性、条件可学习性与目标一致性必须分别成立。 不满足其中一项，都不能由另两项补证。

六、来源与适用边界

以下编号对应本轮实际打开的原论文，完整记录见 sources.csv。S01为原刊扫描镜像；S07仅核对§1，后文定向抓取超时，未用其后文作证据。检索是主题性研究，不声称穷尽。

来源	精确位置	支持命题	限度
S01 Wolpert, *Stacked Generalization*	§§2.2–2.4；Fig.4；p.242脚注2	在排除实例预测上学习level-one；不限共同凸池	单模型也可能胜过stacking；无普适提升保证
S02 Breiman, *Stacked Regressions*	§§1–2；定理1，p.52	加和一约束时风险为 $\alpha^{\top} R\alpha$；单一k最优 iff $R_{kk} \le R_{ik}\ \forall i$	非负权不等于凸权；固定平方误差几何不是动态Top1定理
S03 Ting–Witten, *Issues in Stacked Generalization*	§2、§2.2；§3表3–4	完整概率意见；类特定线性系数	特定数据与学习器；输出分数非自动校准概率
S04 Cruz等, *META-DES*	§§3.2.2.1–3.2.3；算法1；表1、图2	正确性元目标；邻域、输出profile与置信度特征	元样本相关；硬投票不能选无人投票类别；不移植其阈值
S05 Yao等, *Bayesian Hierarchical Stacking*	§§2.3–2.4，式11–14；§3.2定理1–4	条件、部分汇聚权重及log-score理论	定理1是目标值近似，非正确率权重等式；定理4需强分离和精确已知区域；专家索引≠solver动作
S06 Gneiting–Ranjan, *Combining Predictive Distributions*	§2；§3.1定理3.1(c)、3.2	指定条件下固定正权线性池过离散、缺乏coherence	需要相异性、正则性等条件；coherence指条件法则，不是所有动态多类池的否定
S07 Gneiting–Raftery, *Strictly Proper Scoring Rules*	仅§1定义	无约束预测空间中真实分布唯一优化期望评分	不推出经验评分改善必然改变动作；不引用后文
S08 Williamson等, *Composite Multiclass Losses*	Definition 2；Proposition 3，pp.7–8	连续严格proper与所有内点c的c-calibration；均匀c对应argmax一致性	总体、无约束条件结论；不覆盖有限优化、受限凸包或实例成本幅度
S09 Duchi等, *Multiclass Classification, Information, Divergence, and Surrogate Risk*	§3.2定义3.1、式13；§§4.1–4.3，定理1–2	成本校准不同于0–1；跨全部先验的普适等价要求广义熵仿射关系	固定表示一致性不能认证联合压缩；类代价矩阵不能编码实例全成本
S10 Elmachtoub–Grigas, *Smart Predict, then Optimize*	§3.2定义3.5、命题3.6；§4假设4、定理4.2	SPO决策损失；SPO+凸上界	一致性需唯一条件均值最优、中心对称、全空间连续密度和非空内点；单纯形在环境空间内点为空，保存单次成本也不满足自动套用条件

授权边界

本文仅作科学研究解释，不提供执行顺序或配方。D1结构族教师标签采集及当前四项主实验保持不动；不现在加入R125，也不在四项结束后自动加入。任何后续行动均须另行授权。

附录：引用编号与下载链接

以下仅机械汇总 sources.csv 原始编号、题名和 URL，不改写科学正文。

S01 Stacked Generalization

https://cafri-labs.github.io/lab-manual/papers/wolpert1992.pdf

S02 Stacked Regressions

https://statistics.berkeley.edu/sites/default/files/tech-reports/367.pdf

S03 Issues in Stacked Generalization

https://arxiv.org/pdf/1105.5466

S04 META-DES: A Dynamic Ensemble Selection Framework using Meta-Learning

https://arxiv.org/pdf/1810.01270

S05 Bayesian hierarchical stacking: Some models are (somewhere) useful

https://arxiv.org/pdf/2101.08954

S06 Combining Predictive Distributions

https://arxiv.org/pdf/1106.1638

S07 Strictly Proper Scoring Rules, Prediction, and Estimation

https://sites.stat.washington.edu/people/raftery/Research/PDF/Gneiting2007jasa.pdf

S08 Composite Multiclass Losses

https://jmlr.org/papers/volume17/14-294/14-294.pdf

S09 Multiclass Classification, Information, Divergence, and Surrogate Risk

https://arxiv.org/pdf/1603.00126

S10 Smart Predict, then Optimize

https://arxiv.org/html/1710.08005v5