R116 之后：从终局分数改造转向实例优势证据

研究日期：2026-10-27。范围：原始论文研究与下一步重大科学问题；不含实验计划、实现或结果审计。

本稿依据 Sol 提供的 REQUEST.md 与 EVIDENCE.md，接受已经发表的 R115/R116 结果，不重新认证数值或代码。当前会话记录的模型为 gpt-6-astra，推理强度为 max。所有新方向均为待验证假说，不是新的实验成功。来源的版本、实际阅读章节与外推限制见 sources.csv；三条方向的机器可读摘要见 directions.csv。

1. 先回答三个问题

为什么很多不同方法仍然卡在约 71%？ 已有证据支持“精细的实例优势尚未被可靠定位”，不支持“所有方法只是同一个模型”“一定存在隐藏 bug”“标签都是随机的”或“已经达到准确率上限”。历史方法确实改变过监督、表示和计算，但很多改变仍从相近输入学习终局胜负，或者学习了与实际候选执行不完全对应的代理过程。多个有限版本阴性，不能把所有这些机制同时判死；反过来，也不能仅凭尚未穷尽就不断重启。

现在最值得优先改变什么？ 主推荐是候选相关的异构原生计算表征：将实际预训练求解模块作用于当前合法输入时形成的节点、边、方向角色和状态条件化特征，作为选择器的表示基础。重点不是再拼几个 encoder，也不是给方法名称或源码做 embedding，而是检验外部学到的候选计算是否提供了现有共享表示未能利用的优势线索。只有不读取查询解、成本或轨迹，且不变成隐蔽求解的形式，才属于这里的建议。

最强反驳是什么？ R102 已加入 TSP 的 ELG 和 ATSP 的 MatNet，预训练臂并未胜过额外随机 donor 臂；R106 微调同批 donor 也未带来突破。更根本地，候选获胜可能由完整解码、增广或后处理的微小差别决定，任何廉价的输入侧激活都不足以预测。这个反驳比“还没有覆盖所有候选”更重要。主方向应接受同结构、同状态、同推理计算的新增原生预训练权重对匹配随机权重比较，而不是靠历史跨版本涨点证明机制。

优先级	重大方向	真正改变的对象	为什么不是同一条路线的换名
1，主推荐	异构原生计算表征	当前实例上、保留候选计算类型的表示	部署时使用既有预训练算子，不要求新增原生过程标签
2，替代方向	TRAIN 上下文参与结构形成	由历史有标签图集条件化的选择函数	不依赖原生候选权重或过程标注，改变既有 TRAIN 知识的调用方式
3，高风险储备	原生 TRAIN 过程的决策相关学习	从输入预测候选状态演化的学生模型	新增的是训练期执行知识；部署不调用原生教师，也不读取查询过程

三者不建议同时组合。组合后即使提升，也难以知道是外部权重、历史样本条件化还是过程知识起作用。排序表达科学优先级，不是开跑顺序或资源承诺。

2. R115/R116 到底改变了哪些判断？

2.1 R116：排序变好了，但关键召回没有恢复

R116 是完整 whole18 匹配比较。A 使用固定的全候选集淘汰偏好，B 按剩余集合重算非线性上下文；两者都做精确全路径冠军 DP，不是贪心对 DP。两者也使用相同的冠军 CE 与完整排序 NLL 组合，因此它提供的是剩余集合条件化的证据，不是某个 loss 单独优越的证据。

同口径指标	R116 A	R116 B	历史 R94B
TEST Top1	71.134568%	71.255556%	71.577778%
TEST actual regret	0.404762%	0.402782%	0.379115%

同口径指标	R116 A	R116 B	历史 R94B
固定36组真实 winner 命中数 / 4598	10	18	117
固定36组 winner recall	0.2175%	0.3915%	2.5446%

表中 R94B 是历史锁定结果，不能解释为与 R116 同初始化的机制消融。ALL 沿用逐题等权；winner 为 native FP64 ind；actual regret 是逐实例相对 Oracle 的损失，不是均值成本之比。

B 的 TEST 排序 NLL 从 0.583866 降至 0.564418，相对改善约 3.3%；冠军 NLL 也从 0.698717 降至 0.693839。与此同时，固定36组仅命中 18/4598，明显少于历史 117/4598。B 在这些组选择34次，其中18真、16假，精确率52.94%；相对 R94B 救回6例、失去105例。TSP 中 LEHD 有762个真实 winner、DIFUSCO 有334个，B 对两者仍均零选择。

这支持“改善排序似然不充分”的判断，但尚不能断言改善全部发生在排序尾部，也不能由总体 NLL 确定是哪种实例证据缺失。完整排序对很多非冠军关系都有贡献；略微改善概率，未必让真正漏选的方法越过当前实例的第一名。

B 相对 A 在 TEST 纠正796例、损害698例，净增98例；但正式 VAL 接受条件失败，Top1 只增加0.035802469个百分点，actual regret 和 vs_SBS 均变差。CVRP TEST 更直接体现两种目标的冲突：Top1 增加0.533333个百分点，regret 却增加0.048287148个百分点。因此不能根据 TEST 的微小正值晋升 B，也不能把减少零选择组数当成成功。已有推理开销符合当时约束，不能用“DP 没有真正算完”解释阴性。

2.2 R115：降低响应路线优先级，不宣布神经响应不可能

R115 检验的是 714维固定统计特征上的小样本 Ridge，不是原始图上的神经响应算子。每题仅32个基础实例，两折各16个 base；每个干预族的拟合折约32个成对样本，还共享基础实例。全部512个 base 是跨16题总数，不是某一条件下有512个独立训练样本。

四个预先指定条件均输给零响应和训练折均值控制。例如 CVRP-demand 的 MAE 为1.256850，对照为0.816604和0.839936；OVRPTW-tw_center 为5.062264，对照为2.521884和2.559576。这些单位是固定 TRAIN 折成本尺度的百分比，不是 selector regret。预设继续条件失败，应撤下“已有响应足以支持扩展”的推论。

高维、小样本、固定统计、线性映射与同 base 相关，共同限制该阴性的外推范围；它没有否定所有非线性、图级或候选条件化响应学习。但“线性失败不代表神经失败”只保留可能性，不构成自动增加标注或换大网络的理由。R114 的定向与随机干预幅度还未严格匹配，不能把差异全部归因为方向；其采集也没有覆盖 TSP/ATSP。故本稿不将响应学习继续列为前三主线。

3. 零选择与全局平台，需要分开解释

3.1 零选择可以合法，但不是可以忽略

设选择器实际保留的表示为 Z。即使每类都有正例，某类也可能在所有 Z 上都不是最大后验。例如 $P(Y|Z)=(0.45,0.35,0.20)$ 时，第三类有20%的真实频率，却从不应被准确率最优的 argmax 选中。这个例子只说明正例频率不推出选择配额，不表示当前任务真实后验已经被估计出来。

尤其要区分两层命题：相对于有损表示 Z 的不可分，与相对于完整输入 X 的不可预测。若冻结运行条件下 winner 是 X 的确定函数，粗表示上混在一起不等于原始输入中没有信息；若还有未观察的执行随机性，也必须有相应证据才能量化不可预测部分。现有实验没有给出 Bayes 上限估计。

历史 v2 报告还显示，LEHD 与 DIFUSCO 的漏选形态并不相同：前者相对更常接近前列，后者连提前排序都较弱。R94B 上两者 TRAIN 召回也很低，不能简单归因于测试过拟合；小 TRAIN-VAL 差同样不是优化收敛证书。见 前期深度报告第3至5节。这些是历史模型的诊断，不是对 R116 重新计算的结论。

3.2 Top1、平均成本与 regret 不是同一目标

三个理想决策一般不同：

argmax_k P(Y=k|X)；argmin_k E[C_k|X]；argmin_k E[(C_k-C*)/C*|X]。

这里 C* 是该实例合法候选池的 Oracle 成本。即使成本预测无偏，最小期望成本也不必最大化 native winner 一致率；最后一种还带有逐实例分母。R116 的 CVRP 结果已经给出实际例子，不需要为此再设计一个新的损失系数。

直接的算法选择论文也有类似警示：Seiler 等人的 TSP 工作比较 EAX/LKH 的 PAR10，节点图像、MST 图像和近邻图像具有不同误选代价；加入更多图像通道并不保证更好。该研究是特意演化的二候选 TSP，不是当前 whole18 的固定预算成本选择，其阈值调整也不是本稿建议。Feature-Free Algorithm Selection，2020，§5.1–5.2

3.3 固定36组不是整个平台

历史 R94B 的错误中约80.54%在固定目标清单之外。这个比例只用于说明全局范围，不当成 R116 当前错误分解。一个方向若只让 LEHD 多被选几次，或恢复少数 ReLD 对的胜负，却伤害常见候选之间的判断，不能完成 whole18 目标。

因此，本稿关注的是优势证据能否在完整候选竞争中成立，而不是“让每个方法都有输出”。候选单独 AUC、辅助任务准确率、排序似然、平均选择数量都只能作中间证据。最终需要同一个锁定模型下真实命中与误选代价的联合改善。

4. 已经试过什么，真正缺什么？

以下是学习对象的覆盖总结，不是重新检查完整性，也不将历史不同数据和协议拼成排行榜。

历史方向	已经覆盖的内容	不能再称为空白的内容；仍未等价覆盖的边界
记忆与局部专家：R47/R48/R49/R53	检索键值、差分记忆、局部二分类、有限样本记忆能力	不能说“从未用 TRAIN 标签”或“从未做专家”；不等于全池的原始图条件函数学习
donor：R50/R94/R102/R106	双 ReLD 窄任务；16题 ReLD；再加 ELG/MatNet；冻结与微调	不能说“TSP/ATSP 从未迁移”；也不能说所有候选原生计算都已迁移
结构与计算：R54/R55/R56/R63/R92/R99/R107/R112	路线辅助、计费边差、有向边、候选循环工作区、层级图、矩阵步骤、三元关系与区域接口	高阶、递归、层级不再自动新颖；未学准的 latent 接口不是精确资源程序
目标与容量：R67/R71/R78/R81/R82/R84/R88/R89/R91/R93/R104	表示预训练、联合成本分布、候选对/对比目标、focal、物理节点角色、优化器、链接与扩容	不能以“再预测相关成本”“再换 loss/head”包装重大方向；个别小正值不等于所有方法全负
数据与外部上下文：R77/R97/R98/R100/R101	增加独立样本；表格 ICL 的 winner/cost/pair；TRAIN hints	不能说 ICL 或数据量从未试过；不等于上下文在查询结构压缩前参与计算

历史方向	已经覆盖的内容	不能再称为空白的内容；仍未等价覆盖的边界
候选私有化：R109/R110	晚期私有节点计算、不同监督形式	R109 的 TRAIN 拟合及部分召回改善未转成整体联合收益；不等于异构预训练知识已用尽
过程与响应：R113/R114/R115	短合成过程、16题响应采集、小线性跨 base 筛查	合成转移不等于原生候选执行；采集不等于可泛化的神经响应模型
全排序：R116	剩余集合重算、完整排序监督、精确冠军边缘化	继续加排序头缺乏优先依据；概率组织改变不等于实例证据增加

覆盖来源为 第一版深度报告、第二版深度报告、综合报告、大范式报告及 R109–R114 后续报告。R115/R116 以本目录 EVIDENCE 为准。

最重要的覆盖修正：R94 不是全候选 native transfer，但 R102 也绝不能被遗漏。 只为理解学习对象阅读的实现表明，r94_donor.py 是16个非 TSP/ATSP 问题的冻结 ReLD 静态编码节点特征；r102_donor.py 增加 ELG/MatNet encoder，仍不执行环境或解码。MatNet 的 FROM/TO 角色也已保留，不应重新宣称“方向角色从未进入模型”。

R94 的预训练相对随机 donor 有过约0.288个百分点 TEST Top1 改善，说明这一类计算知识至少曾产生有限正效应。相反，R102 的新增预训练臂相对新增随机臂约低0.36个百分点，R106 微调也不占优。两者合在一起支持的不是“迁移一定有效”，而是：知识来源、计算阶段和下游所需信息之间是否匹配，仍是可检验问题。

5. 原始论文带来的实质约束

本轮对15篇原始论文的相关方法、假设或实验部分进行了实际访问与阅读，明显超出上一报告的文献集合。下面只保留改变判断的内容，不把论文榜单成绩换算为预期 selector 涨点。预印本按实际读取版本记录，未读到的正式修订不冒充已读。

5.1 求解器的“知识”并不都位于 encoder

LEHD：浅 encoder 不代表弱候选，关键计算可能在动态部分。 原文把大量计算放在重新编码剩余子问题的 heavy decoder；仅抽浅 encoder 不等于抽取其主要策略能力。§6.2 的同监督比较与组件实验说明计算位置影响求解泛化，但不证明这种中间特征能识别 LEHD 何时胜过其他方法。LEHD，NeurIPS 2023，§3–4、§6.2

DIFUSCO：它处理的是图与带噪解变量，不是普通静态节点图。 TSP 的扩散变量位于边上，网络同时使用图、噪声状态和时间；最终质量还取决于热图解码及后处理。因此一个输入图的静态 embedding 或单次热图，不等于实际候选的完整性能，也不能把 diffusion 输出置信度当作原生成本。DIFUSCO，NeurIPS 2023，§3.3–3.5、§4.1–4.3

MatNet：类型化表示有具体含义，不只是加宽特征。 原文用分离的行/列节点更新与矩阵元素混合注意力，ATSP 解码区分出发与到达角色。这说明保留表示类型有方法依据；但当前 R102 已经覆盖相应 encoder 与双角色，不能将其重新列为未经测试的新机制。MatNet，NeurIPS 2021，§3.1–3.3、§4

ReLD：静态表征与当前条件的结合才构成策略。 原文区分不随步骤变化的节点表示、当前容量等状态以及可行节点集合；改善求解策略不只是让静态特征更大。本稿据此划清 R94 的覆盖范围，不据此建议另一个 ReLD decoder、局部专家或候选淘汰头。ReLD，2025，§2.1–2.3

CaDA：多约束候选也有不同的表示知识。 约束 prompt 在编码过程中与全局/稀疏分支交互，原文消融支持这些组件对其16种 VRP 求解有贡献。它提示 whole18 研究不能只盯 TSP；但 task prompt 本身不能区分同题

实例，原生求解改善也不是 selector transfer 的证据。本轮读取的是2024年 arXiv v1。CaDA，§IV-B–D、§V-E

MoSES：层级、逐 token 的已有策略复用，不等于静态方法 ID。 原文实际方案复用 LoRA 专家并学习组合；理论则依赖最优基策略、状态分解及表示混合假设。不能把那些条件直接赋予我们的有限近似候选，更不能把“组合出统一求解器”当成“选择已有候选”的保证。八个 B 任务中被删除的 MoSES 仍不恢复。MoSES，NeurIPS 2025，§4.1–4.3、§5.1/5.3、§6

还有一个容易误用的跨领域依据：DIFT 能从扩散模型取对应特征，但它给已观察图像加噪；DIFUSCO 的干净变量却是未知解。 因而不能为了复用 DIFT 技巧，把查询真实路线加噪再送入网络。只用输入图和独立噪声提取中间特征，是另一个尚待验证的假说。Emergent Correspondence from Image Diffusion，NeurIPS 2023，§3–4、附录 B/C

综合判断： 论文支持“原生计算异构，抽取位置重要”，不支持“收齐模型权重便会解决漏选”。从输入合法可得的激活，到完整候选优劣之间，仍缺少本项目的因果比较。

5.2 历史标签可以参与结构学习，但不能凭空创造任务

Transformer Neural Processes（TNP） 将上下文的输入与标签绑定，并约束上下文排列不变性。其 wheel bandit 实验预测多个动作收益，但来自有明确参数变化的任务族，并在测试中得到在线奖励；不能直接类比我们只用冻结 TRAIN 上下文的一次性选择。TNP，ICML 2022，§3.1–3.3、§4.3–4.5

PRODIGY 把图数据与标签节点组成 prompt graph，并以特定 in-context 任务预训练，而不只是给固定 embedding 做最近邻投票。实际证据主要是引用网络和知识图谱的节点/边分类；数据点共享源图，标签节点还是信息瓶颈。它不是独立路由整图间精细比较已经成功的证据。PRODIGY，NeurIPS 2023，§2.1–3.2、§4.3–4.5

Context-aware Graph Meta-learning（CAGML） 在上下文推理中加入结构检索和图卷积，消融显示结构有价值；然而去掉保留原始语义的残差时性能大幅下降。论文使用 PLM 文本节点特征，且将无文本图列为未来工作。这是对本项目外推的强限制，不是可以直接加载的路由基础模型。CAGML，AAAI 2026，§3.1–3.4、§4.5–4.7、§5

综合判断： 文献支持把“如何使用一组已知样本”本身训练成计算过程。它没有证明 frozen90k 能被随机切成很多真正独立的函数任务，更没有证明邻近几何意味着相同 winner。早期结构条件化是明确的覆盖差异，但仍须对抗既有检索和表格 ICL 阴性。

5.3 更多训练期知识，何时才真能转移？

LuPTS 研究训练时可见、预测时不可见的后续状态。在 Gaussian-linear Markov 系统及相应噪声条件下，组成转移模型能降低相对直接 OLS 的估计方差；其非 Markov 实验也显示优势受损。原生候选的压缩状态、非线性搜索和 winner 离散边界并不满足这些保证。Using Time-Series Privileged Information，AISTATS 2022，§2–3.1、§4.2–4.3

Rethinking Knowledge Transfer in LUPI 提供必要反证：在所重访实验中，一些蒸馏收益随更多样本或充分训练消失；TRAM 的部分收益可由不含有效特权信息的结构解释。它没有否定全部 LUPI，而是要求区分真实知识转移、结构优势和总训练投入。这里采用实际读到的2024年 v1，不将后续正式版当成已读。Rethinking Knowledge Transfer，§3–5

Neural Algorithmic Reasoning for Combinatorial Optimisation 的 TSP 转移包含冻结、微调和双处理器等方式，冻结并不成功，简单平均两个处理器也不是可靠答案；相关预训练的收益还会随规模和算法执行准确率下降而衰减。论文训练的是求解器，不是固定候选行为的选择模型。NAR for CO，LoG 2023 / PMLR 2024，§4.1–5.3

Value Equivalence 提供对象选择原则：模型未必需要重现所有状态细节，只需保留指定策略和值函数上的 Bellman 作用。但它针对 MDP 回报，不能直接保证 native winner 概率或逐实例 Oracle regret 不变。这里借鉴“面向决策保留信息”，不声称拥有相应定理。The Value Equivalence Principle，NeurIPS 2020，§2–3.2

综合判断： 过程数据最有价值的形式不是“更多辅助标签”，而是可由输入预测、与候选差异相关、且在学生自反馈时仍有效的知识。是否存在这样的可压缩过程，当前尚未证明。

6. 主推荐：异构原生计算表征

6.1 科学假说与学习对象

假说：现有瓶颈的一部分来自计算知识不匹配，而不只是模型容量不足。 通用 selector 从头学习候选胜负，可能难以自行重建不同候选已经学会的几何关系、约束竞争和局部决策偏好。把这些权重应用于当前实例，保留其类型化中间结构，可能让优势边界更容易学习。

可将对象写成：

H_k(X,u) = NativeModule_k(X, u; frozen_pretrained_weights)

a(X) = Selector(X, {typed H_k(X,u)}, legal_pool)。

其中 X 是当前原始实例，u 只能由 X、已知任务条件和与答案独立的参考变量构造。H 可以是节点、边或角色分离的表示，不强迫所有候选先压成同一个全局向量。学习目标仍是全池选择，不输出替代原求解器的新解。被选择的对象是冻结 checkpoint、原生预算、解码、增广与后处理共同定义的候选，不是论文名称；换用另一套权重或流程，不能仍声称预测的是原有 winner 对应行为。

它没有增加查询答案信息。 对固定权重，H 仍是 X 和外生参考变量的函数；科学收益只能来自外部训练知识、归纳偏置和有限样本下的计算效率，不能宣称提高了给定完整 X 的信息论上限。

6.2 推理边界决定这是不是合法新方向

候选计算类型	合法可讨论的输入侧表征	不得偷偷使用的东西
静态多约束模型	原始节点、已知约束、原生双分支或专家层输出	当前实例实际路线、终局质量、根据 query winner 选择 donor
Heavy-decoder 型	已知初始状态，或由输入独立定义的参考边界条件下的隐藏激活	先跑出真实前缀，再称其为“无成本特征”；参考状态冒充原生访问状态
图扩散型	图与答案独立噪声，在明确参考时刻的隐藏节点/边激活	用真实解构造带噪输入；完整去噪、解码、优化后再择优
矩阵型	保留 FROM/TO 与原始矩阵关系的计算输出	宣称 R102 未做双角色；把多次完整解的最小成本当输入

参考状态只是特征计算条件，不是已执行的路线。尤其对 heavy decoder 和扩散模型，偏离原生状态分布可能让特征完全无效。如果有用信号只能在真实 query 轨迹之后出现，这个输入侧方向就不成立，不能悄悄升级成多 solver probing。

在 whole18 上，TSP 的非自回归边计算、ATSP 的矩阵方向计算，以及 CVRP/15种变体的约束相关计算应作为不同知识类型理解。不能为了改善 TSP 两个方法而把其余16题仅列为附带测试，也不要求所有候选机械地拥有相同模块。无可用原生表征的候选仍在合法竞争池中，但其计算覆盖必须标成未覆盖，不虚构“全候选知识已经齐备”。本稿没有核验全部 checkpoint 可提取性，不假定该工程资产已经备好。

6.3 与最近失败先例的非等价性

与 R109 的区别不是参数更多或分支更私有，而是分支内有从独立求解训练得到、应用于当前 X 的计算权重。与 R102 的区别不是从三种 donor 增加到更多，而是允许与实际候选结构匹配的边变量、状态条件化计算和多约束分支，不把所有知识都等同于静态 encoder。若最终实现只剩“更多 encoder 拼接”，就应承认它只是 R102 的扩展，而非本稿的强假说。

R50 的双 ReLD 二分类不覆盖这种异构知识；R51 的短真实行为探测则跨入了执行信息，本方向不借其权限。R112 的条件接口与 R113 的合成过程也没有提供实际候选的原生权重。以上只证明不等价，不能证明新对象更有价值。

6.4 最强反对理由

第一，外部知识可能只教会“怎样找到好解”，并未教会“自己何时相对失败”。 多个求解器都能形成合理几何特征，差异却由完整决策序列的偶然分叉决定。若这些差异不体现在合法参考状态中，原生表征的来源再真实也无济于事。

第二，已经存在相当接近的负例。 R102 预训练不如随机、R106 微调不占优，直接削弱“更多领域预训练自然有效”的叙事。R94 的有限正效应只支持值得区分来源，不支持外推为数量越多越好。

第三，共享有用特征不等于保留比较信息。 若所有 donor 都只编码共同的难度和成本尺度，选择器可能更准地预测“大家都难”，却不能分辨谁更好。候选表示强行对齐到一个公共空间，也可能消除真正有用的差异；所谓异构不是把维度统一后就算完成。

第四，计算账可能不成立。 多个冻结网络、边张量和参考条件在两张24GB卡上并非免费；反复重编码可能接近原生求解成本。只避免梯度并不能保证显存和时延合理。这里不承诺资源可行性，具体有限形式由 Sol 决定。

6.5 一个决定性科学比较

保持全18数据、合法池、已有参考 donor、选择主干、训练目标、参考输入状态与推理路径一致，只让新增异构原生算子的权重分别来自真实预训练与匹配随机初始化；新增算子均冻结。 随机化仅发生于特征算子，不替换合法池中的实际求解器，也不改变其成本标签。两边保留相同形状和计算，必要的特征尺度处理只能由 TRAIN 确定且对称进行。不能把已有 ReLD 知识从控制臂删掉，也不能一边走更多状态、另一边只算一次。

这个比较直接问：在同一种候选原生计算形式下，外部学到的知识是否产生可迁移的全池优势证据？ 它不试图用一组比较证明每一种组件都必要。若预训练臂仅提高辅助分离度或固定36组出场数，却未改善真正命中与全局成本，主假说没有兑现。若两臂类似，则不能把跨历史版本的共同变化归功于预训练；若随机更好，则应降低这套原生知识迁移的优先级，而非立即叠加 ICL 或蒸馏救场。

7. 第二方向：让 TRAIN 上下文参与结构形成

7.1 科学对象

这不是再次把统计特征交给 TabICL，而是学习：

f_theta(X_query | {(X_j, Y_j, C_j)} from TRAIN)。

上下文是完整实例及其历史监督，输入与标签必须成对绑定；在查询节点、边和候选交互尚未压缩完成时，上下文就能改变计算。成本标签只属于合法 TRAIN 支持集，查询端始终没有答案。一个可能的机制是：根据有标签支持图形成候选条件信息，再调节查询图中哪些几何/约束关系值得比较，而不是先用不变 encoder 丢掉细节，最后补一个记忆残差。

这是前期报告已提出但尚未充分覆盖的强版本，不是本轮首次发明 ICL。其新意是知识使用的时机与结构，不是支持集更大、输出从 winner 换 cost，或再做一个可训练近邻。

7.2 最近阴性与最强反对理由

R47 已尝试可训练记忆；R97/R98/R100 覆盖 winner、cost 和 pair 等表格上下文；R101 的 TRAIN hints 也没有带来大突破。所以“只要利用历史标签就行”已经站不住。它们没有等价检验从原始图开始的结构条件化，但留下了很高的举证责任。

最强反对是这里可能没有适合 meta-learning 的函数变化。 冻结候选和分布下，各实例都来自同一组固定求解映射；把 TRAIN 任意分 episode 不会生成新函数。上下文可能只重述先验或检索相似实例，而没有可适应的局部规律。路由图之间也没有自然的节点对应，不能把不同实例的第 i 个节点当作同一实体。

上述图 ICL 论文大多依赖共享源图、同质性或文本语义。即使学会其架构，独立坐标图上的 winner 边界仍可能很不平滑。另一方面，过早把全部图展平进注意力会有严重计算负担；可缓存上下文独立特征，不等于可免费缓存查询相关的交互。

7.3 一个决定性科学比较

用相同 TRAIN 支持实例、原始图信息、标签、候选池和匹配的容量/计算，比较上下文在查询结构形成阶段进入，与同等强度的上下文仅在结构压缩后进入。 后者也必须是训练过的图上下文模型，不能用一个弱统计分类器充当控制。唯一核心区别是查询细粒度结构是否能被有标签上下文条件化。

若早期条件化没有优于强晚期控制，就不应把“上下文已经看得更多”当成功，也不应自动扩大上下文量。若它仅记住方法频率而未形成真实实例优势，固定36召回和误选成本仍会暴露问题。比较不要求另开在线反馈：支持集只能来自冻结 TRAIN；预测 TRAIN 时排除当前实例及同 base 关联副本，VAL/TEST/LIB 标签均不能进入上下文。

8. 第三方向：学习原生过程，但只保留决策需要的部分

8.1 科学对象与权限边界

目标不是完全复制每个候选的最终路线，而是学习能预测其相对表现的状态演化：

z_k,0 = Init_theta(X,k)；z_k,t+1 = Transition_theta(X,k,z_k,t)；a = Readout_theta(X,{z_k,t})。

未来可用原生候选在冻结 TRAIN 上产生的过程作监督，例如资源竞争、被排除的动作集合、关键结构改变及与后续质量相关的状态。这里列的是潜在知识类型，不是采集清单；本轮没有获得或生成新标注。哪些状态既能从输入预测，又保留候选差异，是这个方向本身的科学问题。

部署时只运行学生的内部预测过程，不调用原生教师，不读取 query 路线、成本或实际中间状态，也不通过完整候选求解获得 Oracle。它与主方向不同：主方向直接调用既有权重提供表示，这里则花训练期标注代价，把执行知识转移到另一个模型。

8.2 最近失败先例不能回避

R113 的合成连续转移相对静态快照在 TEST Top1 约差0.129630个百分点、actual regret 约差0.003228个百分点，且二者部署都保留自反馈，不能说“旧模型没有执行过程”。R54/R55/R61 的结构与路线知识也已经表明，附加结构监督并不自动改善选择；R115 又提醒，观测到响应不意味着它容易跨实例预测。

本方向的非等价处在于监督来源是当前原生候选的实际计算，而不是通用短程序或仅终局结构。但这仍是知识来源变化，不是理论豁免。若学生学不准前序状态，或者那些状态只描述共同难度，更多真实轨迹也可能浪费资源。

8.3 最强反对理由

完整的 native 行为可能比 winner 更难学。多个候选在大部分状态上相似，决定细微胜负的却是少数难预测事件；平均状态误差下降，并不保证这些事件改善。反过来，若只监督一个压缩状态，还可能丢掉决定后续行为的历史，使其不再 Markov。不能用 LuPTS 的线性系统保证替代这一缺口。

更不能把强教师的表现当作学生证据。教师在训练时已经看见实际过程，自然更容易判断结果；学生部署只看 X，能否恢复相关信息才是问题。连续自反馈还有误差累积，teacher-forced 的状态准确率不等于真实选择能力。

因此，本方向低于前两者。所谓“决策相关压缩”也不是另一个成本回归头：必须保留可解释的状态演化关系；若最终只预测终局相关成本，R71 等已构成最近先例。如果只有完整路线重建才有用，则应明确那是更重的行为模拟问题，而不是当前建议已获支持。

8.4 一个决定性科学比较

在同一批原生 TRAIN 状态与同一学生计算结构上，比较有方向的状态转移学习，与按阶段从输入直接学习状态快照。 两边拥有相同终局监督和状态信息总量，部署均只能依赖自身预测；控制臂不是无额外训练的弱模型，也不是把真实状态乱序后伪造物理错误转移。

核心问题是：真实原生过程中的条件连接，是否比拥有同样状态标签的静态学习，更能支持最终选择？ 如果仅状态预测更准而 whole18 决策不变，就反对“过程精度足以转成优势证据”这条桥梁。若两者相当，也不能宣布原生时间结构有效。该比较不解决所有蒸馏问题，但足以决定是否值得继续押注“原生动态优于快照”的强版本。

9. 为什么不推荐其他看似自然的下一步？

不再优先完整排序的变体。 R116 已证明更好排序似然可以与极弱 winner recall 并存；继续增加淘汰层、温度、候选交互 head 或小损失项，缺少新知识依据。排序不是理论上无用，而是当前边际研究价值下降。

不以配额、偏置或静态稀有类补偿当重大方向。 真正要恢复的是这些方法胜出的实例，而不是它们的列频率。类频率不能定义最优选择比例，错误的恢复还会带来成本损害。

不把更大模型、更长训练、纯输入自监督直接当主要答案。 R104、相关预训练与结构实验已经留下反证；当然也未穷尽所有优化。输入重建可能只学习共同几何，不能自动识别固定候选的比较残差。没有新的任务相关理由，不应靠规模或 foundation model 命名晋升。

不把 R115 的阴性变成扩大响应采集的理由。 原始图神经响应仍是合法研究领域，但本轮没有证据足以恢复其第一优先级。新 TRAIN 标注虽获允许，是否值得获取仍取决于清楚的科学对象，不是权限本身。

不将 benchmark 语义修复变成本报告的先决任务。 R58 保持延期；本稿研究的是冻结版本的实际候选表现，不将其宣称为统一形式语义下的所有求解器能力。这个限制需保留，但不是重新开启审计的命令。

10. 给 Sol 的科学结论与解释边界

主结论：停止把问题主要描述成“如何重新安排已有分数”，优先问“现有表示缺少哪一种能定位候选优势的计算知识”。 异构原生计算表征目前最值得排第一，因为它连接了有限的 R94 正证据、明确但不完整的迁移覆盖，以及原论文展示的实质计算差异；同时，它也有 R102/R106 这样足够接近、必须正面接受的反例。排序第一不代表预期必然超过历史 R94B。

三条方向的知识增量和失败方式必须分开：原生表征若失败，说明这套合法输入侧计算没有兑现价值；上下文若失败，说明既有 TRAIN 知识的这一种调用方式不够；过程学习若失败，说明这套原生执行知识未能转成学生的有效决策。没有一项阴性可以单独证明“平台不可突破”，也没有一项辅助正值能宣布研究目标完成。

后续科学解释继续遵守冻结90k与全18合法池：八个 B 任务不恢复 RouteFinder、MoSES_RF、MoSES_CaDA，删除的 RELD_MTL 不回流，reld_mt 不与其他 ReLD 取最小值。只有一个最终选择的方法，不运行多个完整 solver 后择优。一次完整模型锁定一个 VAL 选出的 checkpoint 与推理规则，TEST/LIB 不能重新选型；这些留出集已参与研发，不称为全新盲测。

判断整体价值仍需同模型的全18 Top1、mean_cost、TRAIN 拟合 SBS、Oracle、vs_SBS、vs_Oracle 与 actual regret，并分别说明固定36组和清单外收益。NSS 四数据集历史对照只作同锁定口径背景：例如 R116B 在 CVRPLIB 为44% Top1，对应历史 NSS 重评70%，不支持宣称新模型普遍超过 NSS；也不把 NSS 写成新90k重训模型。

本稿只交付科学假说、原始文献依据和每条方向的一个辨别性比较。 有限协议、具体状态/上下文选择、batch、学习率、预算、可行性测试与执行均留给 Sol。没有启动训练、测试或 solver，没有采集新过程，没有修改已有成果，也没有产生新的实验成功结论。